

ZÁPADOČESKÁ UNIVERZITA V PLZNI

FORMÁLNÍ JAZYKY A PŘEKLADAČE KIV/FJP

"Java" do PL/0

Čarnogurský Jan, Vojtěch Danišík A19N0025P, A19N0028P cagy@students.zcu.cz, danisik@students.zcu.cz

Obsah

1	Zad	
	1.1	Tvorba překladače zvoleného jazyka
	1.2	Bodované náležitosti
2	Náv	rh jazyka
	2.1	Zvolené konstrukce
	2.2	Struktura jazyka
		2.2.1 Omezení jazyka
		2.2.2 Ukázky jednotlivých konstrukcí
3	Imp	lementace
	3.1	Struktura projektu
	3.2	Princip funkčnosti
		3.2.1 Parsování vstupního souboru
		3.2.2 Průchod stromu
		3.2.3 Struktury v paměti
		3.2.4 Začátek generování instrukcí
		3.2.5 Prototypy metod
		3.2.6 Generování instrukcí
		3.2.7 Nastavení adres u volání metod
		3.2.8 Nastavení levelů u volání metod
		3.2.9 Zápis instrukcí do souboru
	3.3	Viditelnost proměnných
	3.4	Volání metod s parametry
	3.5	Metoda s návratovou hodnotou
	3.6	Error kódy
4	Tes	ování 1:
5	Uži	vatelská dokumentace 12
6	Záv	ér 1:
	6.1	Omezení při volání metod
	6.2	Zhodnocení výsledků

1 Zadání

1.1 Tvorba překladače zvoleného jazyka

Cílem práce bude vytvoření překladače zvoleného jazyka. Je možné inspirovat se jazykem PL/0, vybrat si podmnožinu nějakého existujícího jazyka nebo si navrhnout jazyk zcela vlastní. Dále je také potřeba zvolit si pro jakou architekturu bude jazyk překládán (doporučeny jsou instrukce PL/0, ale je možné zvolit jakoukoliv instrukční sadu pro kterou budete mít interpret).

Jazyk musí mít minimálně následující konstrukce:

- definice celočíselných proměnných
- definice celočíselných konstant
- přiřazení
- základní aritmetiku a logiku (+, -, *, /, AND, OR, negace a závorky, operátory pro porovnání čísel)
- cyklus (libovolný)
- jednoduchou podmínku (if bez else)
- definice podprogramu (procedura, funkce, metoda) a jeho volání

Překladač který bude umět tyto základní věci bude hodnocen deseti body. Další body (alespoň do minimálních 20) je možné získat na základě rozšíření, jsou rozděleny do dvou skupin, jednodušší za jeden bod a složitější za dva až tři body. Další rozšíření je možno doplnit po konzultaci, s ohodnocením podle odhadnuté náročnosti.

Jednoduché rozšíření (1 bod):

- každý další typ cyklu (for, do .. while, while .. do, repeat .. unitl, foreach pro pole)
- else větev
- datový typ boolean a logické operace s ním
- datový typ real (s celočíselnými instrukcemi)
- datový typ string (s operátory pro spojování řětezců)

- rozvětvená podmínka (switch, case)
- násobné přiřazení (a = b = c = d = 3;)
- podmíněné přiřazení / ternární operátor (min = (a ; b) ? a : b;)
- paralelní přiřazení (a, b, c, d = 1, 2, 3, 4;)
- příkazy pro vstup a výstup (read, write potřebuje vhodné instrukce které bude možné využít)

Složitěší rozšíření (2 body):

- příkaz GOTO (pozor na vzdálené skoky)
- datový typ ratio (s celočíselnými instrukcemi)
- složený datový typ (Record)
- pole a práce s jeho prvky
- operátor pro porovnání řetězců
- parametry předávané hodnotou
- návratová hodnota podprogramu
- objekty bez polymorfismu
- anonymní vnitřní funkce (lambda výrazy)

Rozšíření vyžadující složitější instrukční sadu než má PL/0 (3 body):

- dynamicky přiřazovaná paměť práce s ukazateli
- parametry předávané odkazem
- objektové konstrukce s polymorfním chováním
- instanceof operátor
- anonymní vnitřní funkce (lambda výrazy) které lze předat jako parametr
- mechanismus zpracování výjimek

1.2 Bodované náležitosti

Kromě toho že by program měl fungovat se zohledňují i další věci, které mohou pozitivně nebo negativně ovlivnit bodování:

- testování tvorba rozumné automatické testovací sady +3 body (pro inspiraci hledejte test suit pro LLVM nebo se podívejte na Plum Hall testy, ale jde skutečně jen o inspiraci, stačí výrazně jednodušší řešení). Užitečné a s tručné povídání na dané téma najdete také tady .
- Kvalita dokumentace -x bodů až +2 body podle kvality a prohřešků (vynechaná gramatika, nesrozumitelné věty, příliš chyb a překlepů, bitmapové obrázky pro diagramy s kompresními artefakty, ...).
- \bullet Vedení projektu v GITu -x bodů až +2 body podle důslednosti a struktury příspěvků.
- Kvalita zdrojového textu -x bodů až +2 body podle obecně znýmách pravidel ze ZSWI, PPA a podobně (magická čísla, struktura programu a dekompozice problému, božské třídy a metody, ...)

2 Návrh jazyka

2.1 Zvolené konstrukce

Pro naší semestrální práci jsme zvolili následující konstrukce:

- minimální konstrukce
- zbylé cykly (bez foreach)
- else větev
- datový typ boolean a logické operace s ním
- rozvětvená podmínka (switch, case)
- násobné přiřazení (a = b = c = d = 3;)
- parametry předávané hodnotou
- návratová hodnota podprogramu

2.2 Struktura jazyka

Náš jazyk připomíná Javu, z které vychází. Popis námi zvolené gramatiky je v souboru SimpleJava.g4, který se nachází ve složce se zdrojovými soubory. Pro demonstraci funkčnosti gramatiky jsou v sekci 2.2.2 předvedeny všechny možné konstrukce. Tělo programu musí být umístěno ve složených závorkách.

2.2.1 Omezení jazyka

- jazyk používá striktní typování
- při deklaraci proměnné je vždy nutné nastavit její hodnotu
- z metody nelze vyskočit dřív než před koncem jejího bloku
- void metody neobsahují return
- při rekurzivním volání nelze přistupovat ke globálním proměnným. Viz 6.1
- iterační proměnná for cyklu nesmí být deklarována

2.2.2 Ukázky jednotlivých konstrukcí

Detailnější ukázky programů jsou uloženy ve složce testFiles. Blok programu musí být vždy ve složených závorkách.

Deklarace proměnných

```
{
  const int a = 10;
  boolean b = true;
  int d = c = a;
  int a = volaniMetodyNavratovaHodnota(1, false);
}
```

Deklarace metod

```
{
  int function metoda1(int a, boolean b)
  {
    return a + b;
  }

// pokud je metoda typu void neobsahuje return
  void function metoda2(){}
}
```

Cykly

If else

```
{
   if (a < b)
   {
      // telo
   }
   else
   {
      // telo
   }
}</pre>
```

Rozvětvená podmínka

```
{
    switch(cislo) {
        case 1 :
        {
             // telo
        }
        case 2 :
        {
                  // telo
        }
        default :
        {
                  // telo
        }
    }
}
```

Volání metod

```
{
   volaniMetody(1, true);
   int a = volaniMetodyNavratovaHodnota(1, false);
}
```

3 Implementace

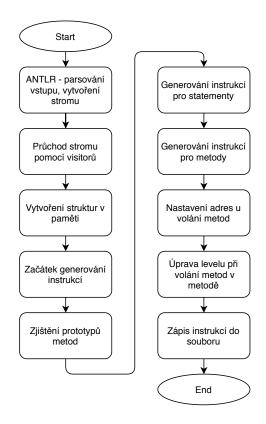
3.1 Struktura projektu

Projekt obsahuje dva hlavní balíky generate a compilator. Balík generate obsahuje třídy vygenerované pomocí ANTLR. Balík compilator obsahuje následující strukturu:

- compilerPart balík, který obsahuje třídy pro generování instrukcí
- enums balík, obsahuje všechny výčtové typy
- error balík s error třídami
- object balík se společnými objekty
- visitor balík, který obsahuje visitory pro průchod derivačního stromu
- Compilator třída, která obsluhuje proces aplikace
- ErrorHandler třída pro obsluhu chyb při generování instrukcí
- InstructionGenerator třída pro spuštění generování instrukcí
- LexerParserErrorListener třída pro obsluhu chyb při parsování vstupního souboru

3.2 Princip funkčnosti

Zpracování je rozděleno do několika kroků. Průběh zpracování je znázorněn na obrázku 1. O průběh zpracování se stará třída Compilator, která jednotlivé bloky spouští. Třída Compilator je volána z třídy Main, a jako parametry jsou předány cesty k vstupnímu a výstupnímu souboru. Kód je generován na dva průchody. Prvním průchodem se uloží derivační strom do paměti a druhým průchodem se z uložených struktur v paměti vygenerují instrukce.



Obrázek 1: Průběh zpracování

3.2.1 Parsování vstupního souboru

Parsování vstupu, vytvoření derivačního stromu, a jeho zpracování je řešeno pomocí ANTLR. Gramatika je popsána v souboru SimpleJava.g4. Soubory vytvořené pomocí ANTLR jsou vygenerovány do balíku generate.

3.2.2 Průchod stromu

Průchod stromu je řešen pomocí visitorů. Jednotlivé visitory jsou uloženy v balíku compilator/visitor. Visitory jsou rozděleny do tříd tak, aby odpovídaly hlavním uzlům v derivačním stromu. Visitory slouží k průchodu stromu, a k jeho následnému uložení do paměti.

3.2.3 Struktury v paměti

Struktury v paměti slouží pro uložení derivačního stromu do paměti, aby s ním bylo možné dále pracovat. Názvy struktur odpovídají hlavním položkám v gramatice. Výsledkem průchodu je objekt Program, který představuje kořen

derivačního stromu a obsahuje odkazy na další objekty (uzly), které obsahují další odkazy.

3.2.4 Začátek generování instrukcí

V této částí je program přepnut do zpracování uložené struktury v paměti. Je zavolána třída InstructionGenerator a je jí předán objekt Program. Výsledkem generování instrukcí je list vygenerovaných instrukcí.

3.2.5 Prototypy metod

Před samotným generováním instrukcí je nejprve nutné zjistit prototypy metod (hlavičky metod), aby při generování volání metod bylo možné určit, jestli metoda má návratovou hodnotu, popřípadě jakého je typu. Prototypy metod nepracují s parametry.

3.2.6 Generování instrukcí

Pro generování instrukcí je připraveno několik tříd, kde každá zpracovává různě námi uložené struktury:

- BaseCompiler abstraktní třída od které jsou další třídy odděděny.
 Obsahuje společné proměnné
- ProgramCompiler zpracovává objekt Program
- BlockCompiler zpracovává objekt Block
- BlockStatementCompiler zpracovává objekt BlockStatement, ve kterém jsou uložena veškerá těla metod. Uvnitř tohoto kompileru jsou volány subpřekladače (ExpressionCompiler, MethodCallCompiler, Methodompiler), dle potřeby
- ExpressionCompiler zpracovává objekt Expression, který představuje veškeré výrazy
- MethodCallCompiler zpracovává objekt MethodCall, který představuje volání metod
- MethodCompiler zpracovává objekt Metod, který představuje deklaraci metod

Generování je rozděleno do dvou kroků. Prvním krokem je vygenerování instrukcí pro hlavní tělo programu, druhým krokem je vygenerování instrukcí pro metody. To způsobí, že začátek programu je vždy ve výsledných instrukcích uložen na adrese jedna a metody jsou uloženy na konci.

3.2.7 Nastavení adres u volání metod

Tím, že je umožněno, aby metody byly vytvořeny až po jejich zavolání, je nutné u instrukcí pro volání metod zpětně nastavit adresu, na které se volaná metoda nachází. Tyto instrukce jsou uloženy s adresou "-1" navíc je to objektu představující instrukci uložen objekt MethodCall.

V cyklu se projdou veškeré instrukce a pokud se jedná o instrukci CALL, je z objektu instrukce získán objekt MethodCall. Zkontroluje se, zda název metody uložený v MethodCall existuje v tabulce symbolů, dále se zkontrolují zda sedí počet a typ parametrů. Pokud není cokoliv splněno je vyhozena chyba a program je ukončen. Pokud je vše splněno, je instrukci CALL změněna adresa podle tabulky symbolů.

3.2.8 Nastavení levelů u volání metod

Při volání metody v metodě je nutné u instrukce CALL zvýšit její level, aby když volaná metoda chtěla přístup ke globální proměnné, tak aby se správně posunula báze.

V cyklu se prochází vygenerované instrukce. Pokud se najde instruce RET, cyklus končí. Pokud se najde instrukce CALL, je iterovací proměnná změněna na adresu instrukce CALL, instrukce se označí jako aktualizovaná a cyklus se opakuje. Pokud se nalezne další instukce CALL v těle volané metody před instrukcí RET, je instrukci uložen předchozí level zvýšen o jedničku, provede se změna iterační hodnoty proměnné a cyklus se opakuje. Metoda pro opravu levelů se nachází v BlockStatementCompiler::updateCallLevel().

Tato implementace nese jistá omezení popsaná v kapitole 6.1.

3.2.9 Zápis instrukcí do souboru

Instrukce se zapíšou do souboru, který byl zadán jako vstupní parametr. V cyklu se projde list instrukcí, který vrátil objekt InstructionGenerator. Pokud výstupní soubor již existuje, je vždy přepsán novými instrukcemi.

3.3 Viditelnost proměnných

Proměnné nadefinované v hlavním těle programu jsou viditelné v celém kódu (jsou celou dobu držené v tabulce symbolů) a je pro ně zvýšen obsah zásobníku. Pro proměnné nadefinované mimo hlavní blok programu (těla metod, těla smyček, ...), je v momentě vykonávání bloku zvýšen obsah zásobníku, a jsou zahrnuty do tabulky symbolů. Po skončení bloku jsou proměnné odstraněny z tabulky symbolů, a je snížen vrchol zásobníku o jejich počet. Tím je zajištěno, že nejsou dále viditelné.

3.4 Volání metod s parametry

Volání metod je řešeno v MethodCall. Pokud má metoda parametry, které je nutné předat, jsou před instrukcí CALL na vrchol zásobníku přidány hodnoty parametrů. V metodě se zvýší vrchol zásobníku o počet parametrů +3 co představuje defaultní velikost metody. Parametry metody jsou získány pomocí instrukce LOD se zápornou hodnotou. Záporná hodnota odpovídá počtu parametrů. Následně se instrukce LOD volá znovu se zápornou hodnotou změnšenou o jedna. To se opakuje dokud se nenačtou všechny parametry. Načtené hodnoty se průběžně ukládají do tabulky symbolů, aby s nimi bylo možné v metodě dále pracovat. Po návratu z metody je ještě nutné předané parametry odstranit z vrcholu zásobníku. Provede se instrukce STO s hodnotou -1, tolikrát, kolik bylo předáno parametrů.

3.5 Metoda s návratovou hodnotou

Volání metody je řešeno v MethodCall. Pokud má metoda návratovou hodnotu, je před instrukcí CALL zvýšen obsah zásobníku o jedna. Výsledek, který metoda vrací je umístěn za klíčovým slovem "return". Po vyhodnocení výsledku je výsledek uložen na adresu počet proměnných +1. Tato adresa odpovídá místu, které se vytvořilo na vrcholu zásobníku jeho zvětšením.

3.6 Error kódy

Program pracuje se svými chybovými kódy. Chyby jsou spravovány pomocí třídy ErrorHandler, která se stará o vypsání chyby a ukončení programu s příslušným kódem. Níže jsou popsány chybové kódy s jejich popisem.

Kód	Popis
1	Proměnná, kterou se snažíte přiřadit neexistuje.
2	Pokoušíte se přepsat hodnotu u konstanty.
3	Při volání metody nesedí počet parametrů.
4	Metoda s tímto jménem již existuje.
5	Metoda, kterou se snažíte zavolat neexistuje.
6	Výsledek výrazu nesedí s očekávaným výsledkem (např. přiřazení matematického výrazu do logického).
7	Návratový typ metody nesedí s proměnnou, do které se přiřazuje.
8	Není možné kombinovat logické a matematické výrazy dohromady (např. true + 10).
9	Snaha přiřadit proměnné typu INT hodnotu BOOLEAN a naopak.
10	Switch nemůže obsahovat více defaultních bloků.
11	Proměnná s tímto názvem již je deklarována.
12	Snaha pracovat s proměnnou, která neexistuje.
13	Při zavolání metody typu void ve výrazu.
14	Typy parametrů metody a typy parametrů ve volání se neshodují.
15	Vstupní soubor neexistuje.
16	Chyba při parsování souboru ANTLR.
17	Neznámá chyba (i když je program otestovaný, může se stát, že se objeví neočekávaná Chyba).
18	Chybné spuštění aplikace, nesedí parametry.
18	Chybná cesta k výstupnímu souboru.

4 Testování

Pro překlad nebyly vytvořeny žádné automatické testy. Testy, které jsme prováděli byly všechny manuální. Všechny námi vytvořené testovací scénáře jsou uloženy ve složce *testFiles*. Pro každý testovací scénář existuje i soubor s výslednými instrukcemi.

5 Uživatelská dokumentace

Pro překlad je nutné mít nainstalovaný Maven. Překlad projektu se provede spuštěním příkazu:

• mvn clean install

Pozor, Maven vytvoří dva jar soubory. Aby bylo možné program spustit je nutné pracovat se souborem, který má v názvu "-jar-with-dependencies".

Pro spuštění je nutné mít nainstalovanou Javu, program se spouští příkazem:

 $\bullet\,$ java -jar <nazev JAR >.jar <v
stupní soubor > ..<výstupní soubor >

Pro demonstraci je vytvořen soubor, který provede ukázkové spuštění.

• Linux : ./run.sh

• Windows : run.bat

V připadě, že nepůjde skript na linuxu spustit je nutné nastavit práva:

 \bullet chmod +x run.bat

Při špatném spuštění, je uživateli vypsána hláška s postupem, jak se program spouští.

6 Závěr

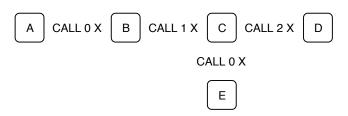
6.1 Omezení při volání metod

Při vývoji byl zjištěn problém, který se nám nepodařilo lépe vyřešit. Problém nastává při úpravě levelu u instrukce CALL (viz 6.1) a projevuje se nemožností přistoupit ke globální proměnné ve dvou případech. Je nutné proměnnou předat jako parametr metody.

Prvním případem, kdy není možné přistoupit ke globální proměnné, je při rekurzivním volání metody. Algoritmus, který je popsán v sekci 6.1 způsoboval zacyklení, bylo tedy nutné ošetřit to, že pokud instrukce CALL volá stejnou adresu jako předešlá instrukce CALL, tak aby algoritmus skončil. Tím ale přestane fungovat přístup ke globální proměnné, protože nejsme schopni posunout správně bázi. Celkový výsledek metody je ale vyhodnocen správně. Testováno přes rekurzivní výpočet Fibonacciho čísla. Testovací scénář je uložen v souboru testFiles/complex/fibonacci.txt.

Druhým případem, kdy není možné přistoupit ke globální proměnné je znázorněn na obrázku 2. Metoda A volá B, B volá C, C volá D, v tomto případě, by přístup ke globální proměnné fungoval správně. Problém ale nastává v momentě, když bude metoda E volat metodu C, která volá D, protože v metodě C je už z prvního volání nastaven posun báze. To způsobí, že nedojde k aktualizaci levelu báze a přistup ke globální proměnné bude fungovat jen v případě volání z A a v případě volání z E to bude přistupovat na špatnou adresu. To že se neprovede aktualizace je způsobeno identifikátorem, který označuje volání za již aktualizované. I kdyby tato značka nebyla nastavena, způsobilo by to to, že by se level upravil a potom by nefungovalo volání z metody A a fungovalo z metody E

Je možné, že tento nedostatek je způsoben špatným návrhem, ale i teď s odstupem času nás nenapadá, jak by bylo možné tuto chybu odstranit. Bylo by nejspíše nutné pokud jeden z těchto dvou případů nastane vytvořit kopii instrukcí pro metodu, u které by se upravil akorát level, to by ale způsobilo to, že by byly instrukce pro metodu uloženy v instrukcích dvakrát. Zároveň by to neřešilo problém s rekurzí.



Obrázek 2: Graf volání metod

6.2 Zhodnocení výsledků

I přes výše zmíněný nedostatek se nám podařilo vytvořit překladač, který dokáže náš vytvořený jazyk převést do instrukční sady PL/0. Pro testování bylo vytvořeno několik scénářů, které demonstrují, že si kompilátor dokáže poradit s jednoduššími, ale i se složitějšími konstrukcemi jako je rekurzivní volání.

Semetrální práce byla vedena na adrese https://github.com/danisik/FJP.